Università Politecnica delle Marche
Facoltà di Ingegneria
Corso di Laurea Magistrale in Ingegneria Informatica e dell'Automazione
A.A. 2024/2025

Progettazione e implementazione di un framework multi-agente per la gestione di un chatbot basato su LLM a supporto degli operatori di una compagnia assicurativa

Relatore
Domenico Ursino

Candidato
Denil Nicolosi

Indice

01 Contesto aziendale e motivazioni

02 Progettazione

03 Implementazione

04 Esempio di conversazione

05 Valutazione

06 Conclusioni e sviluppi futuri

Contesto aziendale

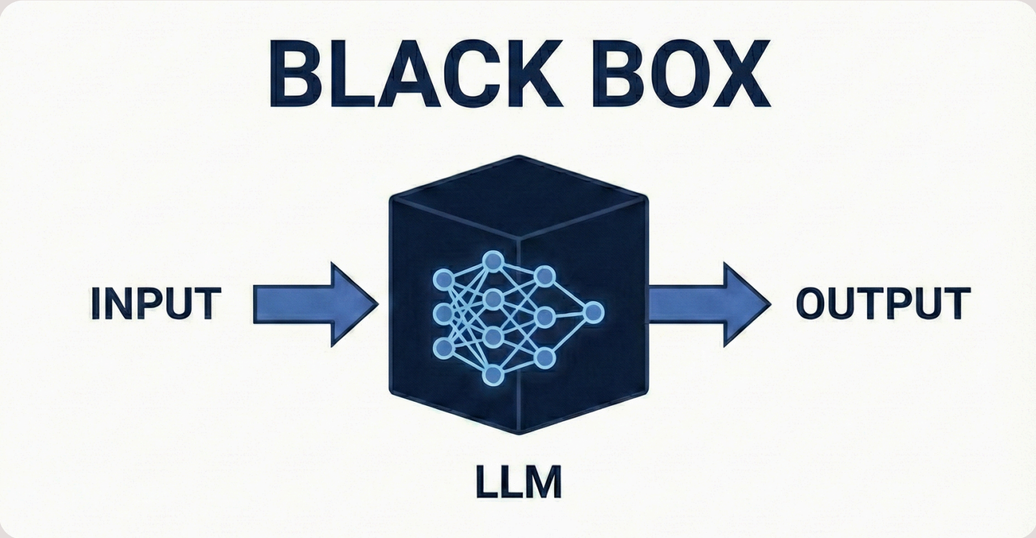
- *Problema*: gli operatori di back-office per gestire una singola richiesta spesso devono **interfacciarsi con diversi sistemi** (database, documentazione, calendario, email)
- *Obiettivo*: sviluppo di una Proof of Concept di un agente che **centralizzi** queste attività in un unico sistema
- *Requisiti aziendali*: affidabilità, manutenibilità, tracciabilità, privacy e controllo umano



REPLY
BLUE

Gli LLM nei processi aziendali

Rappresentano una grande opportunità per automatizzare procedure complesse, ma la loro adozione pone delle sfide strutturali

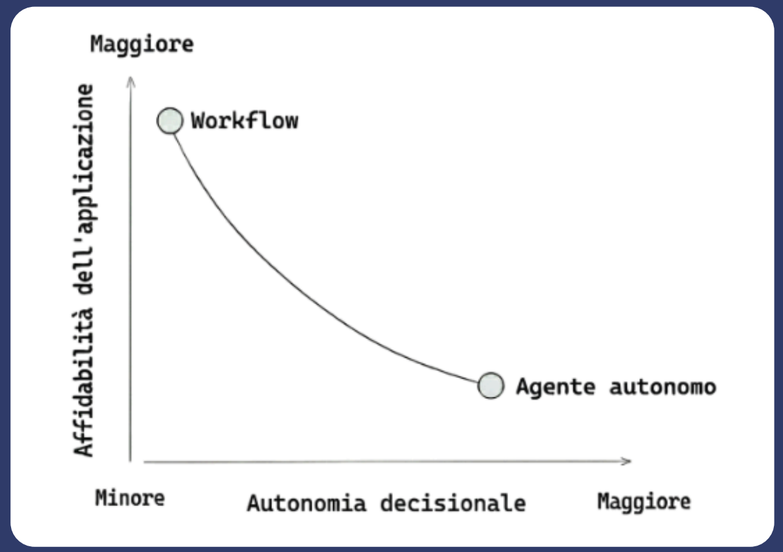


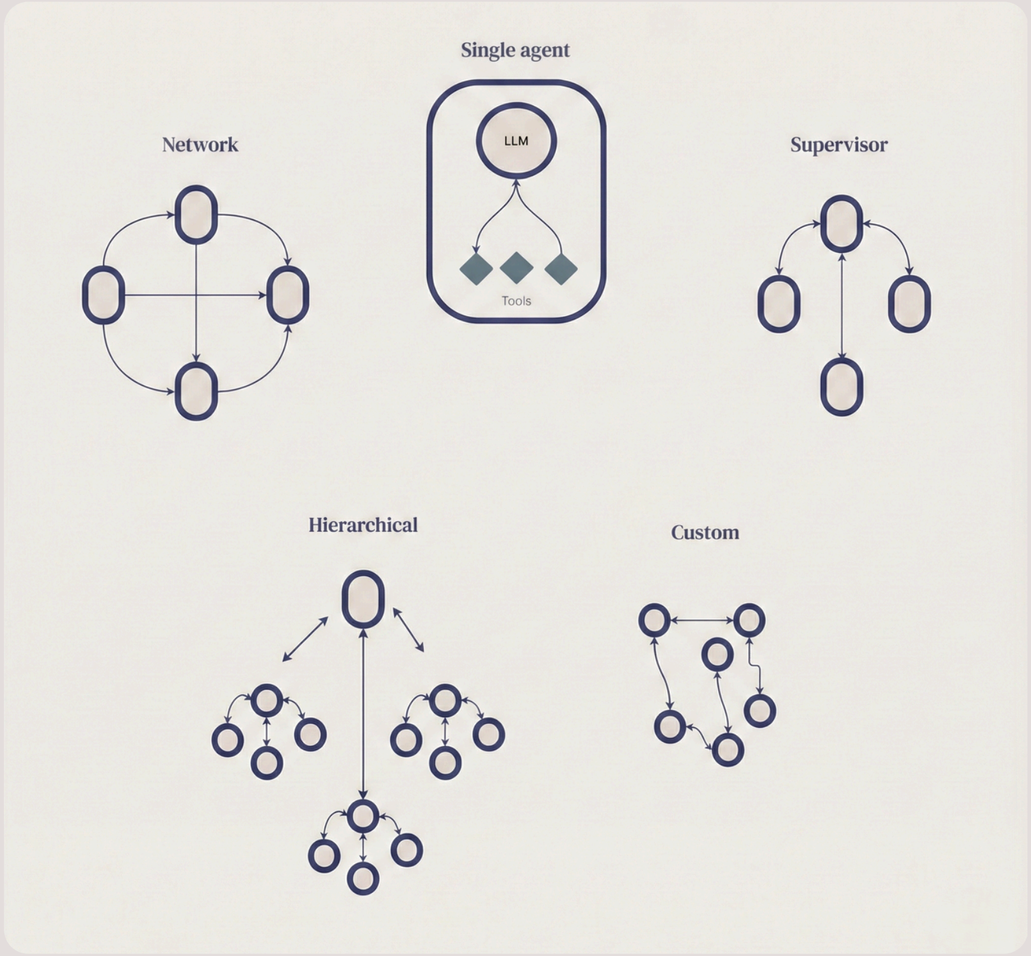
- Mancanza di trasparenza
- Imprevedibilità
- Ingovernabilità
- Allucinazioni
- Privacy

Soluzione multi-agente

Scomposizione del dominio in agenti specializzati:

- Modularità: ogni agente è un unità autonoma
- Flessibilità: modelli LLM specifici per ogni attività
- Trasparenza: sistema ispezionabile nei passaggi



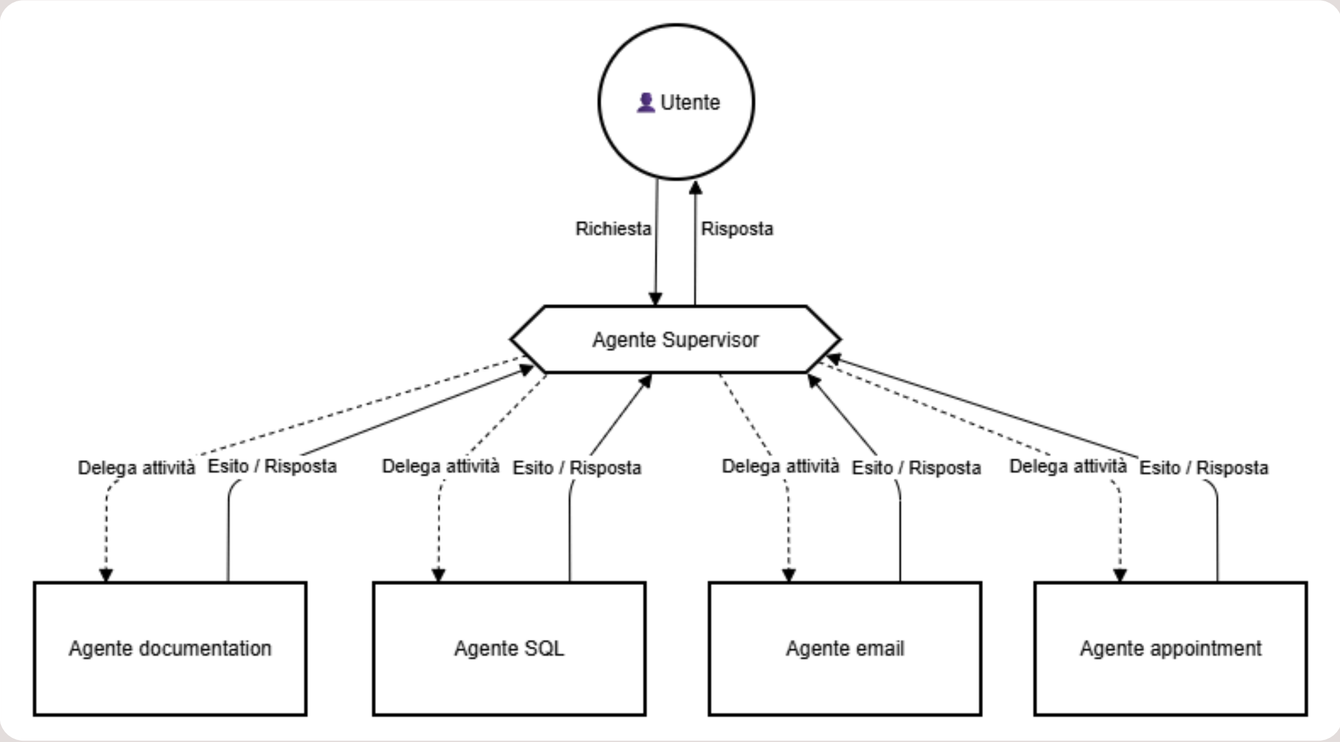


Il pattern Supervisor

Un agente supervisore ha la funzione da coordinatore, mentre gli agenti specializzati eseguono solo attività specifiche richieste da esso.

I sub-agenti non hanno accesso alla conversazione completa ma solo all'attività assegnata.

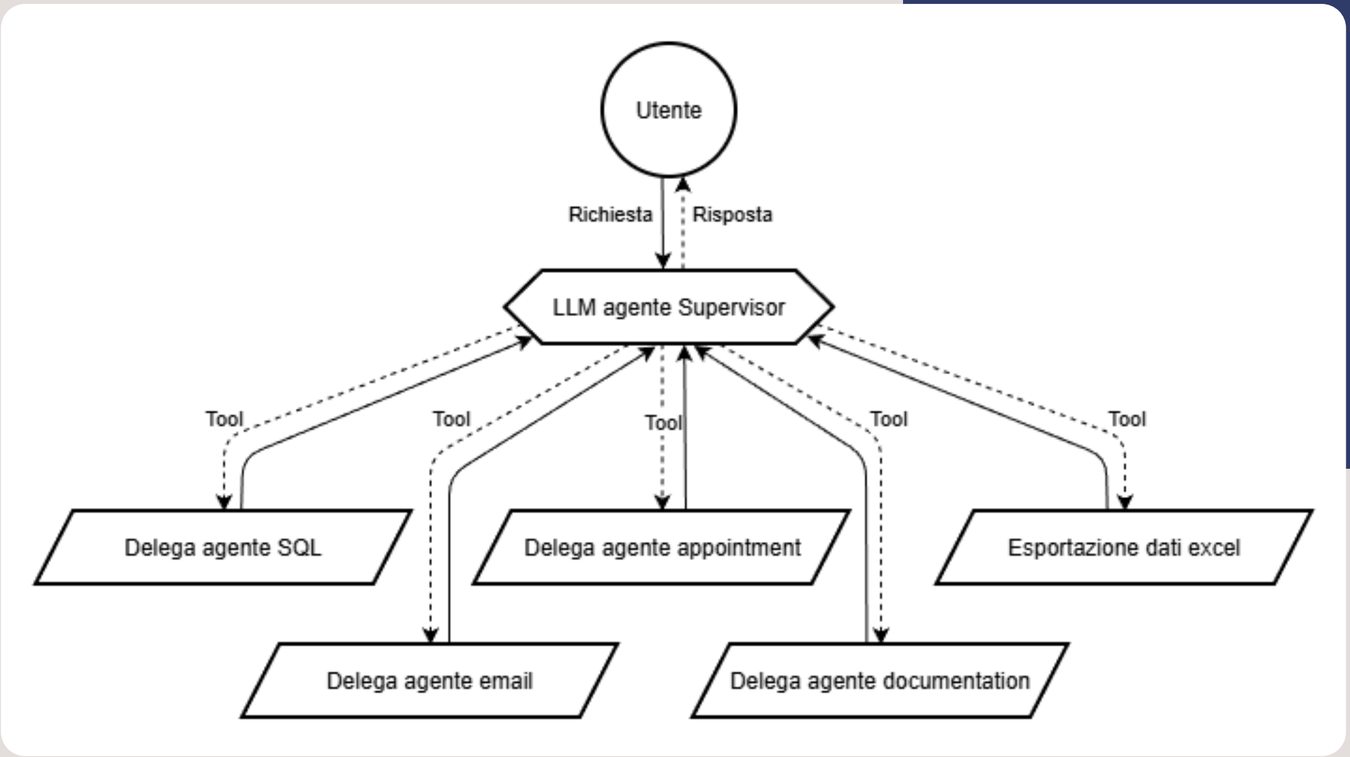
In questo caso sono stati individuati 4 domini di attività.



Agente Supervisor

Il supervisore ha un tool per ogni sub-agente per eseguire l'attività di delega.

Dispone inoltre di un tool aggiuntivo per esportare qualsiasi dato in formato excel.

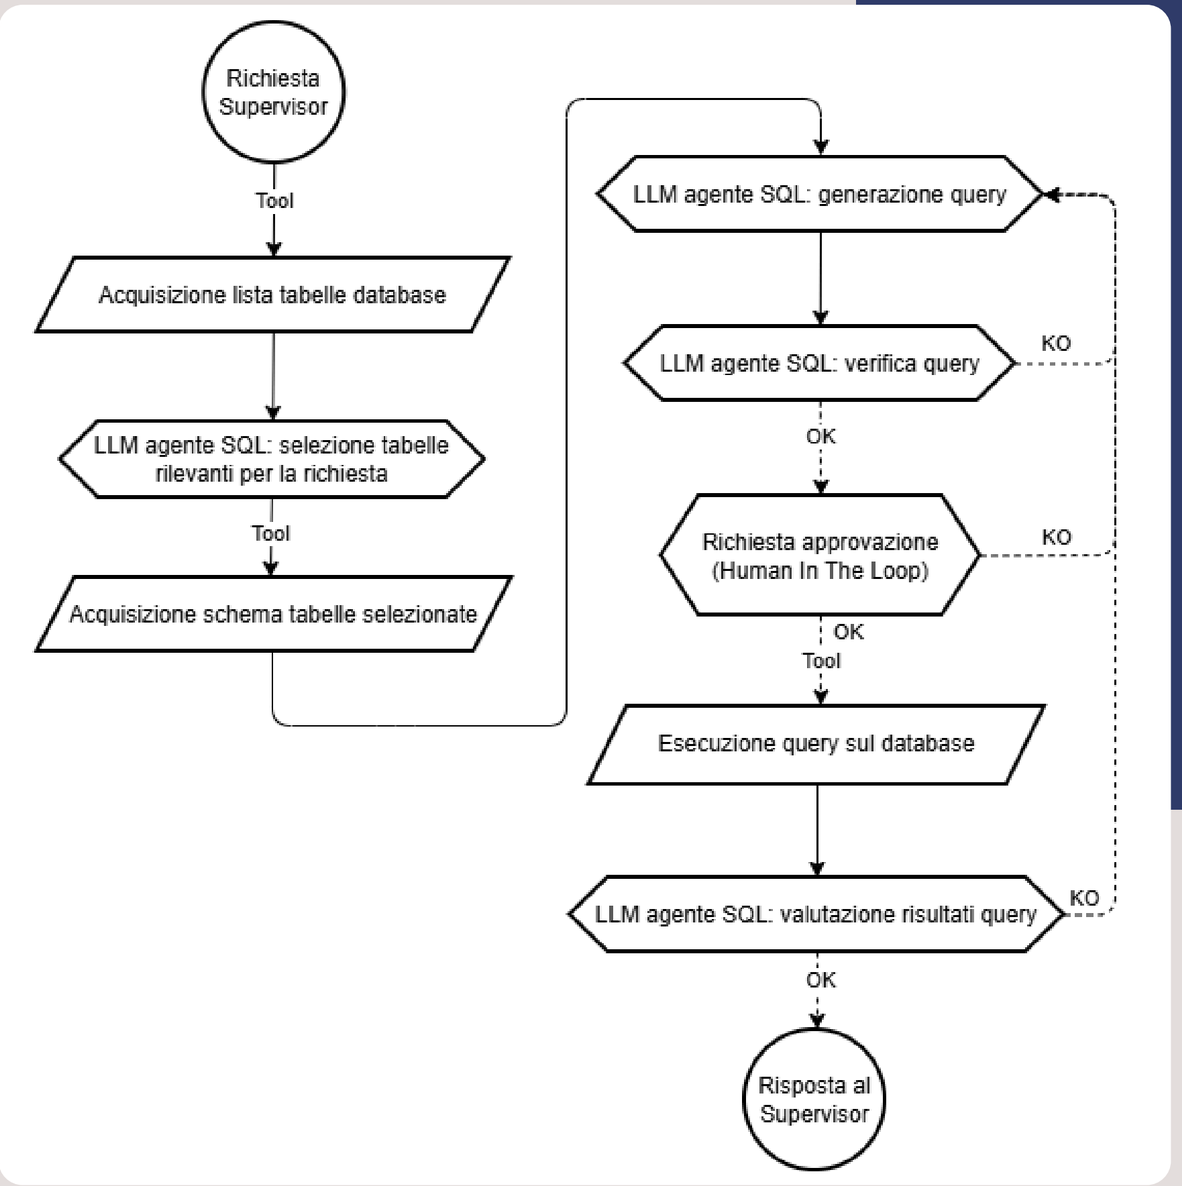


Agente SQL

Questo agente è stato progettato considerando come deterministiche alcune fasi importanti.

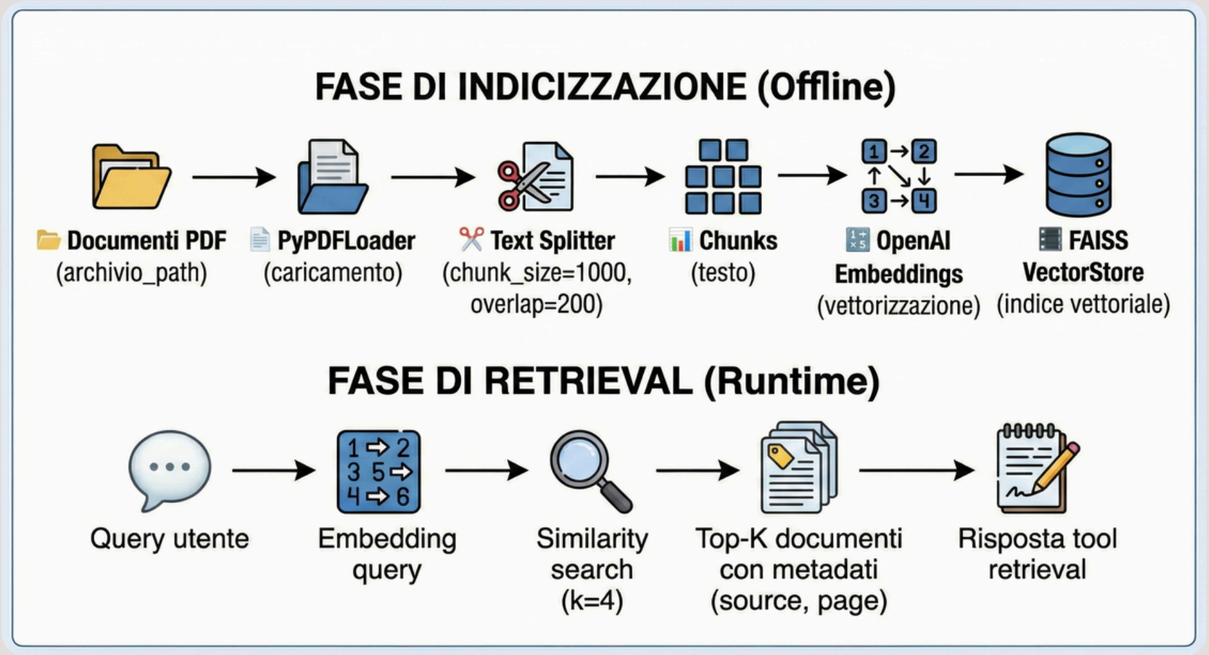
Prima dell'esecuzione, la query deve essere approvata dall'utente

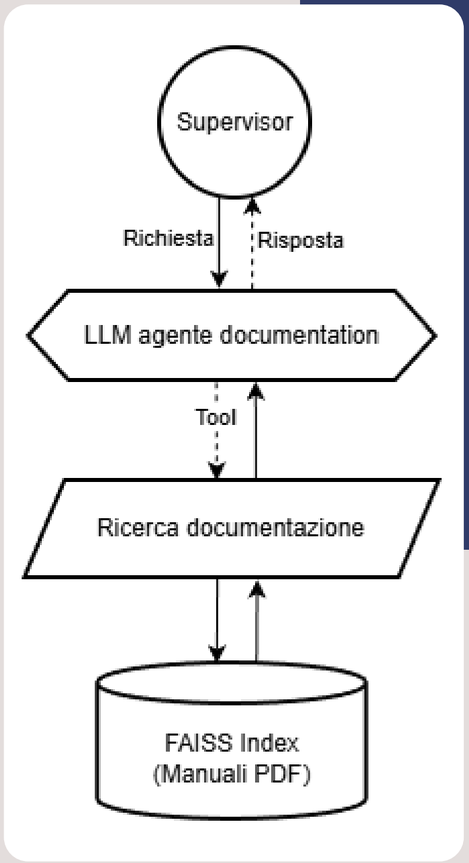
L'implementazione strategica di cicli garantisce un'elevata qualità anche con modelli economici



Agente documentation

Questo agente ha un tool per implementare un sistema RAG sulla documentazione aziendale.

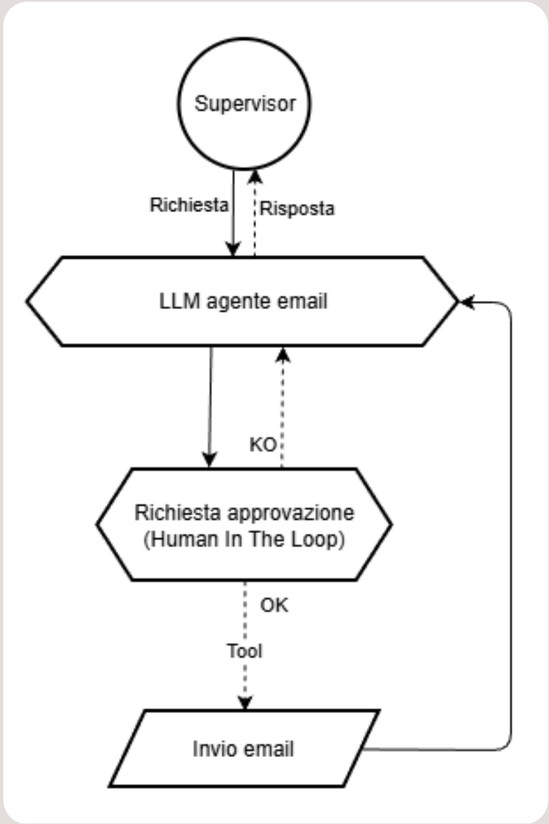


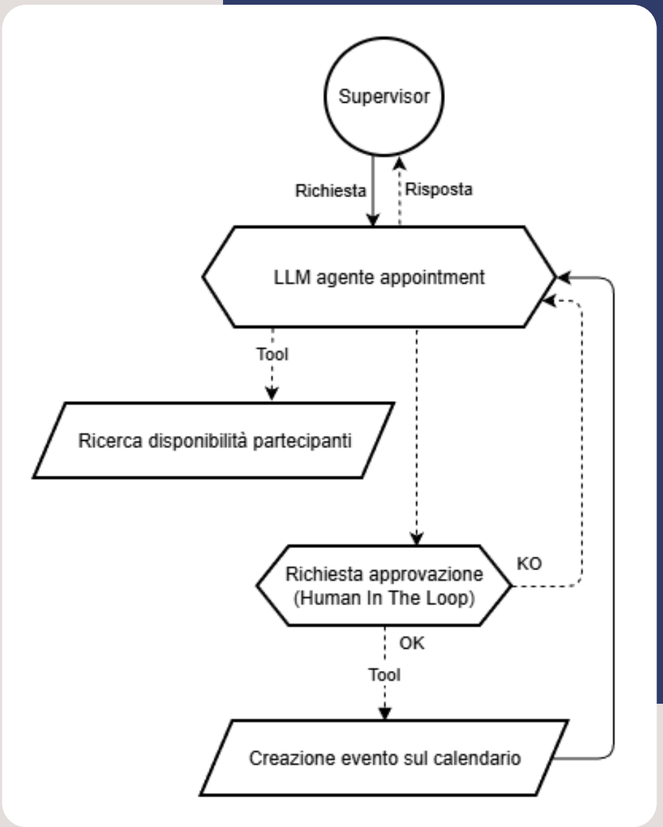


Agente email & appointment

Questi due agenti dispongono di tool con API Google (Gmail e Calendar) per eseguire azioni di supporto all'operatore.

Prima di eseguire le azioni viene richiesta la conferma esplicita da parte dell'utente.



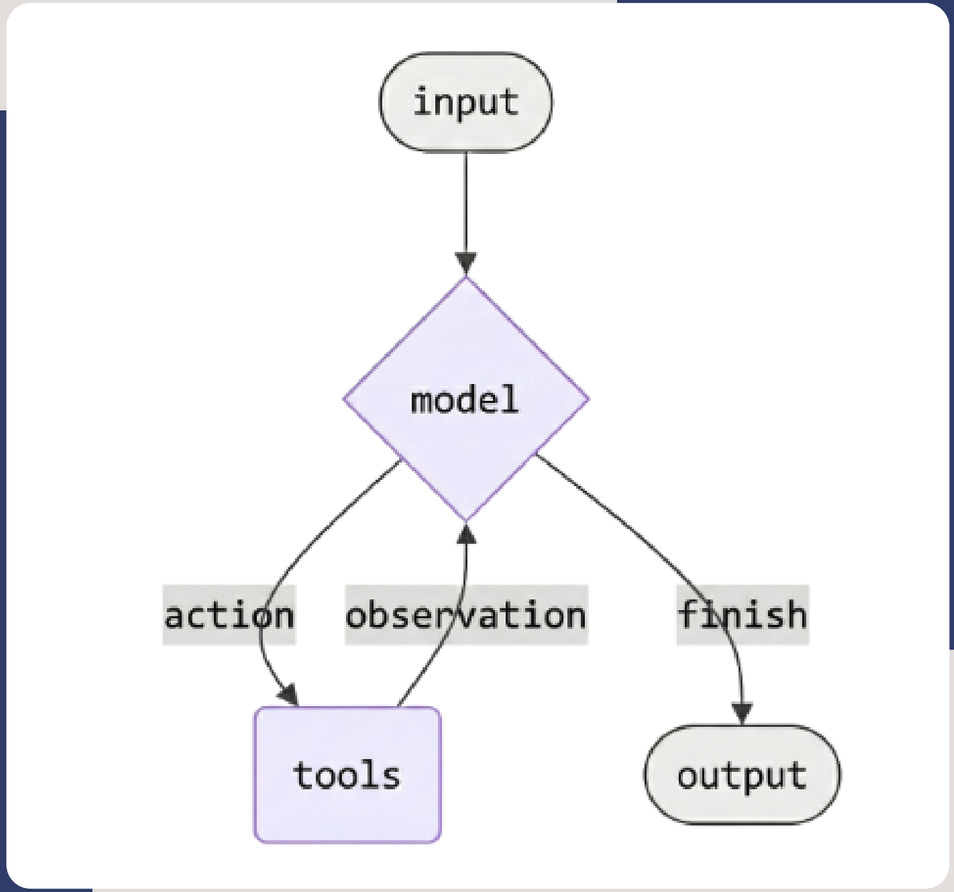


LangChain

Framework per la costruzione di agenti con una interfaccia standardizzata.

```
# LLM Models Configuration
EMAIL_AGENT_MODEL=openai:gpt-5-nano
APPOINTMENT_AGENT_MODEL=openai:gpt-5-nano
SQL_AGENT_MODEL= ollama:qwen3-coder:480b-cloud
DOCUMENTATION_AGENT_MODEL=openai:gpt-5-nano
SUPERVISOR_AGENT_MODEL= openai:gpt-5-mini
```

```python
self.email_agent = create_agent(
    model=init_chat_model(os.getenv('EMAIL_AGENT_MODEL'), temperature=0),
    tools=[send_email],
    system_prompt=EMAIL_AGENT_SYSTEM_PROMPT,
    name="email_agent",
    middleware=[
        HumanInTheLoopMiddleware(
            interrupt_on={"send_email": True},
            description_prefix="Richiesta approvazione invio email",
        ),
    ]
)
```

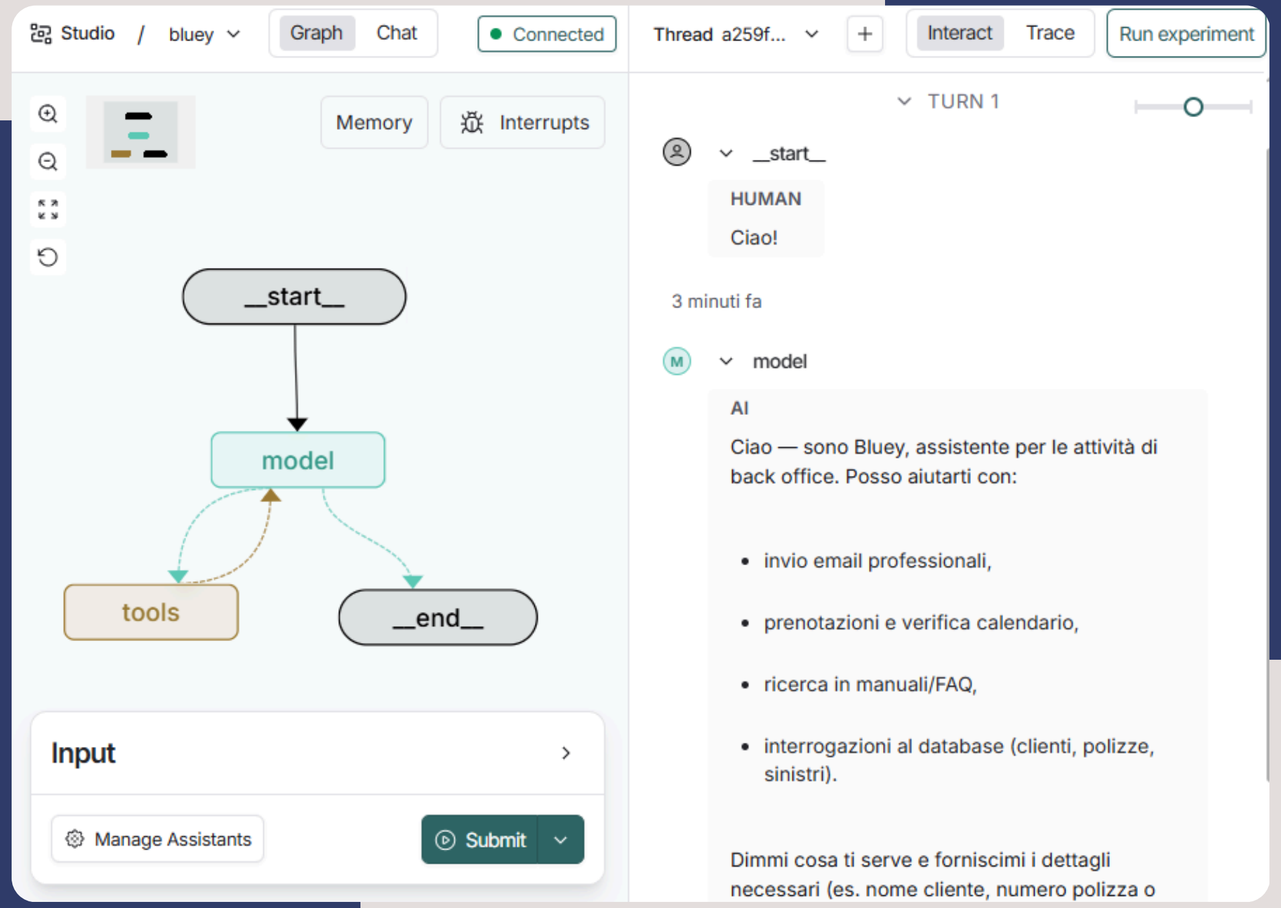


LangGraph

Libreria per orchestrare agenti LLM come grafi di stato.

- Gestione di flussi ciclici e ramificazioni condizionali
- Persistenza dello stato tra invocazioni

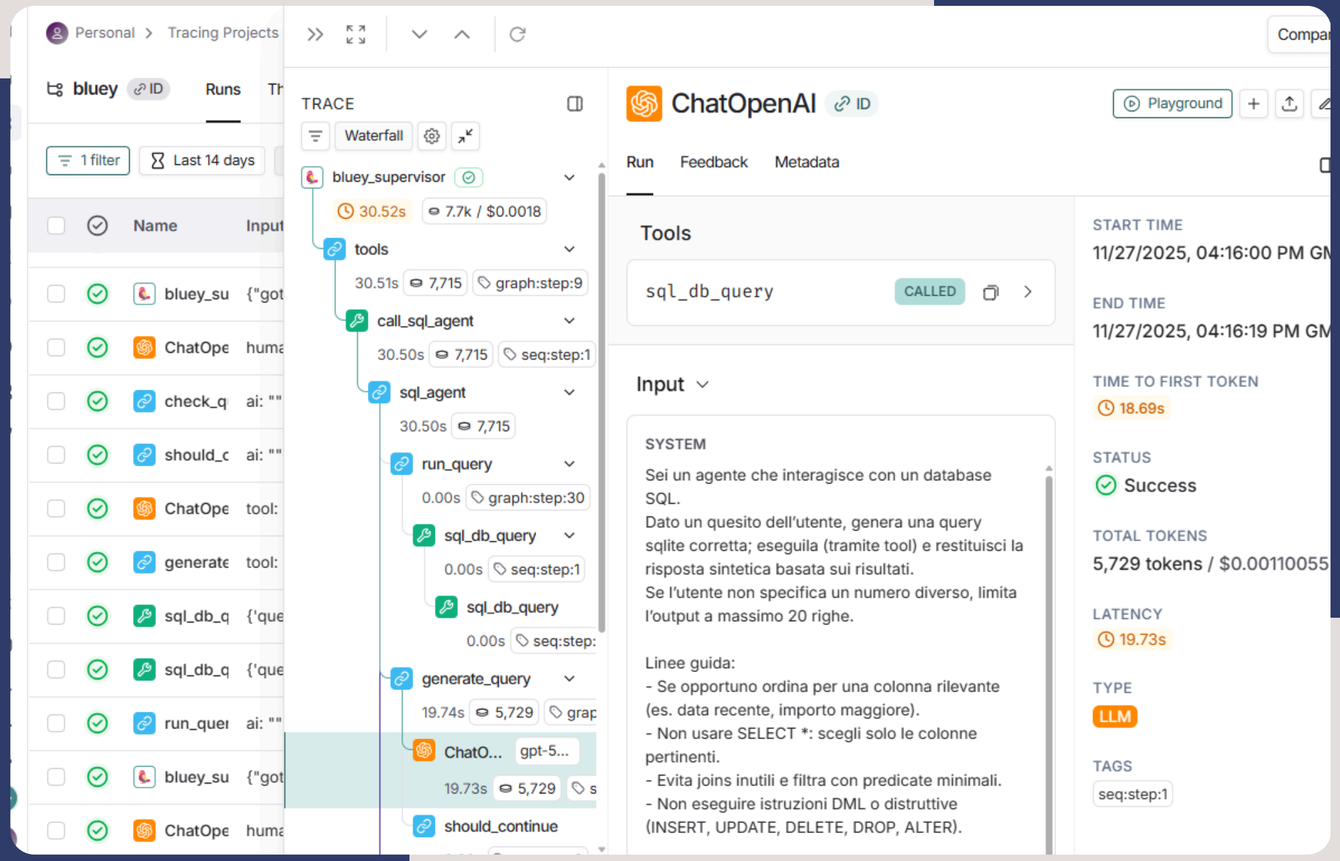
LangGrap studio permette di ispezionare gli agenti graficamente.



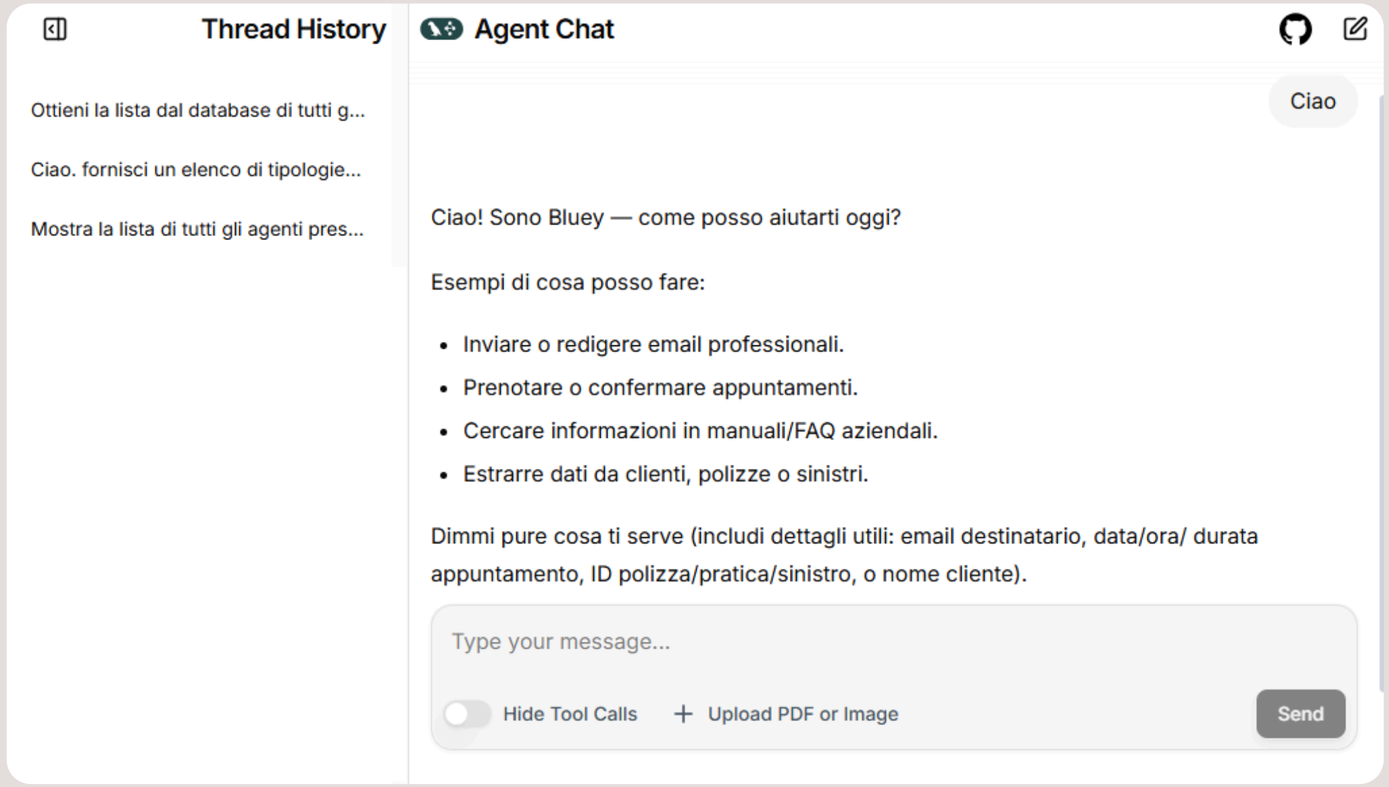
LangSmith

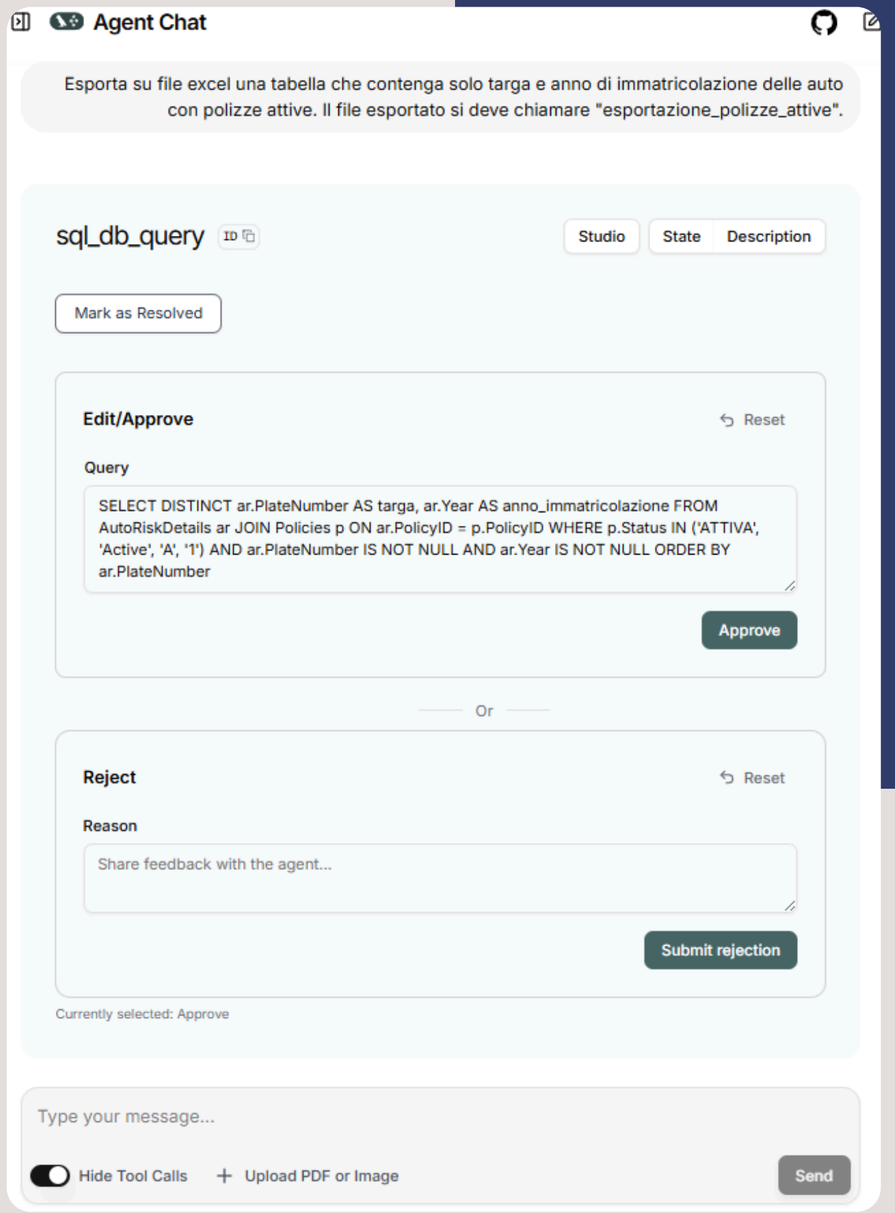
Piattaforma di osservabilità per applicazioni LLM.

- Tracciamento completo di ogni invocazione (input, output, latenza, costi);
- Analisi visuale delle esecuzioni;
- Dataset di valutazione e testing automatizzato.



Agent Chat UI





Demo

Fissa una riunione di 30 minuti per dei chiarimenti per la copertura assicurativa con il titolare della polizza numero 'POL-9201-yubw' per martedì prossimo alle ore 10. Scrivigli poi una mail per comunicargli che la riunione è stata fissata per dare seguito alla sua richiesta pervenuta tramite servizio clienti e che riceverà il link della riunione su google meet circa un ora prima.

call_sql_agent `call_mnPgkLfgdm0965a9LcOUgqmD`

request

1. TASK: Recuperare dati intestatario polizza con numero POL-9201-yubw. 2. CONTESTO: Occorre prenotare riunione e inviare email di notifica al titolare; servono nome, cognome, indirizzo email, numero di telefono e ID cliente. 3. DATI NOTI: Numero polizza = POL-9201-yubw. Richiesta operatore back-office. 4. OUTPUT ATTESO: Tabella con Nome, Cognome, Email principale, Telefono principale, ID cliente, eventuale lingua preferita e note di contatto.

Tool Result: `call_sql_agent` `call_mnPgkLfgdm0965a9LcOUgqmD`

```
SINTESI: Trovato il titolare della polizza POL-9201-yubw - Nome: Alessandro - Cognome: Rossi - Email principale: shucloud1@fudier.com - Telefono principale: +393501475984 - ID cliente: 57 - Lingua preferita: non disponibile nel DB - Note di contatto: non disponibili nel DB Dettagli tecnici: la ricerca è stata eseguita sulle tabelle Policies e Customers. I campi "lingua preferita" e "note di contatto" non esistono nello schema fornito e quindi sono restituiti vuoti; se servono, occorre indicare dove cercarli o aggiungere i campi alla base dati.
```

call_appointment_agent `call_YuiTzuQplioU71Sj3woBH3Oq`

request

1. TASK: Prenotare riunione calendario e generare Google Meet link. 2. CONTESTO: Riunione di 30 minuti con il titolare della polizza per chiarimenti sulla copertura, richiesta da servizio clienti; si deve fissare per martedì prossimo alle 10:00. 3. DATI NOTI: Data proposta = 2026-01-13 (martedì prossimo), Ora inizio = 10:00, Durata = 30 minuti (fino 10:30), Fuso orario = Europe/Rome (CET), Organizzatore = d.nicolosi.reply@gmail.com, Partecipante: Alessandro Rossi (ID cliente 57), Email partecipante = shucloud1@fudier.com, Telefono partecipante = +39 350 147 5984. Oggetto evento = "Chiarimenti copertura assicurativa - POL-9201-yubw". Descrizione evento = "Follow-up richiesta pervenuta tramite servizio clienti relativo alla polizza POL-9201-yubw. Verrà inviato link Google Meet circa 1 ora prima dell'appuntamento.". 4. VINCOLI: Controllare disponibilità dell'organizzatore e del partecipante; creare evento con Google Meet; se l'orario proposto non è disponibile per l'organizzatore, proporre alternative entro la stessa settimana lavorativa (preferenza mattina 09:00-12:30, altrimenti pomeriggio 14:00-17:30) e restituire fino a 2 alternative. Non inviare inviti finali senza confermare disponibilità del partecipante. 5. OUTPUT ATTESO: Conferma se l'evento è stato creato; data/ora finali (con fuso), ID evento/calendario, link Google Meet (se creato), eventuali alternative proposte se slot non disponibile, e eventuale risposta del partecipante (accettato/rifiutato/in attesa).

Tool Result: `call_appointment_agent` `call_YuiTzuQplioU71Sj3woBH3Oq`

```
Conferma: l'evento è stato creato. Dettagli evento - Titolo: Chiarimenti copertura assicurativa - POL-9201-yubw - Data: 13/01/2026 - Orario: 10:00-10:30 (Europe/Rome CET) - Organizzatore: d.nicolosi.reply@gmail.com - Partecipanti: shucloud1@fudier.com, d.nicolosi.reply@gmail.com - Descrizione: Follow-up richiesta pervenuta tramite servizio clienti relativo alla polizza POL-9201-yubw. Verrà inviato link Google Meet circa 1 ora prima dell'appuntamento. ID evento/calendario: non disponibile nell'...
```

Demo

call_email_agent `call_EKmGT63Jxe3bP9XXTutm46gD`

request

1. TASK: Inviare email di notifica appuntamento al titolare della polizza. 2. CONTESTO: È stata fissata una riunione per chiarimenti sulla copertura della polizza POL-9201-yubw come follow-up di una richiesta pervenuta tramite servizio clienti. L'evento è stato creato nel calendario dell'organizzatore (d.nicolosi.reply@gmail.com) per martedì 13/01/2026 ore 10:00-10:30 CET. La mail deve informare il cliente che la riunione è stata fissata e che riceverà il link Google Meet circa 1 ora prima. 3. DATI NOTI: Mittente=d.nicolosi.reply@gmail.com; Destinatario=shucloud1@fudier.com; Nome destinatario=Alessandro Rossi; Polizza=POL-9201-yubw; Data/ora=13/01/2026 10:00-10:30 (Europe/Rome CET); Telefono contatto=+39 350 147 5984. Lingua: italiano. 4. OUTPUT ATTESO: Invio dell'email e conferma: stato invio (inviata/errore), destinatario, oggetto e testo dell'email (anteprima). Oggetto suggerito: "Chiarimenti copertura - POL-9201-yubw | Conferma riunione 13/01 ore 10:00".

Tool Result: `call_email_agent` `call_EKmGT63Jxe3bP9XXTutm46gD`

```
Email inviata! A: shucloud1@fudier.com | Oggetto: Chiarimenti copertura - POL-9201-yubw | Conferma riunione 13/01 ore 10:00
```

Fatto. Ho completato le operazioni richieste:

1. Ho recuperato i dati del titolare della polizza POL-9201-yubw:

- Nome: Alessandro
- Cognome: Rossi
- Email: shucloud1@fudier.com
- Telefono: +39 350 147 5984

↓ Scroll to bottom

Posta in arrivo

d.nicolosi.reply@gmail.com	Chiarimenti copertura - POL-9201-yubw | Conferma riunione 13/01 ore 10:00	Jan 9, 13:14
Denil Nicolosi d.nicolosi.reply@gmail.com	Invitation: Chiarimenti copertura assicurativa - POL-9201-yubw @ Tue Jan 13, 2026 11am - 11:30am (CET) (shucloud1@fudier.com)	Jan 9, 13:11

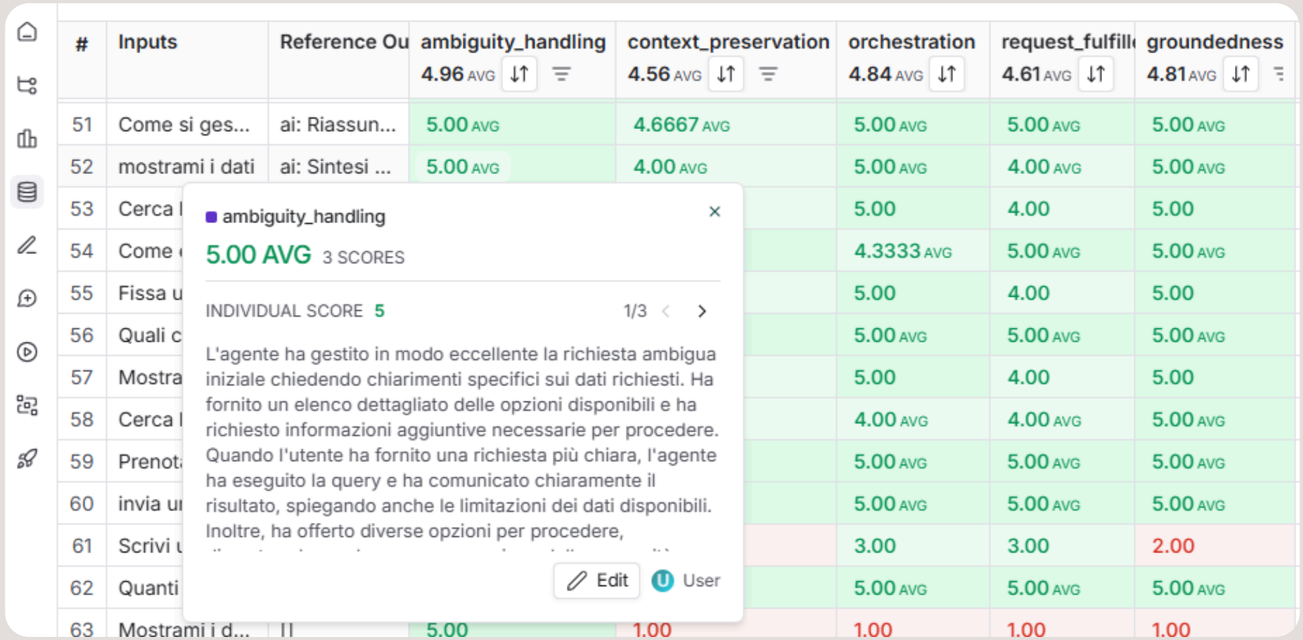
Metodologia di valutazione

- Utente simulato con altro agente LLM
- Approvazione azioni automatica
- Mock delle API esterne

Metriche valutate con LLM-as-a-judge:

- Request fulfilled
- Groundedness
- Ambiguity handling
- Orchestration
- Context preservation

- Dataset di 30 esempi di richieste
- Ogni richiesta viene sottoposta 3 volte
- Ogni valutazione viene ripetuta 3 volte



#	Inputs	Reference Ou	ambiguity_handling 4.96 AVG	context_preservation 4.56 AVG	orchestration 4.84 AVG	request_fulfill 4.61 AVG	groundedness 4.81 AVG
51	Come si ges...	ai: Riassun...	5.00 AVG	4.6667 AVG	5.00 AVG	5.00 AVG	5.00 AVG
52	mostrami i dati	ai: Sintesi ...	5.00 AVG	4.00 AVG	5.00 AVG	4.00 AVG	5.00 AVG
53	Cerca l				5.00	4.00	5.00
54	Come				4.3333 AVG	5.00 AVG	5.00 AVG
55	Fissa u				5.00	4.00	5.00
56	Quali c				5.00 AVG	5.00 AVG	5.00 AVG
57	Mostra				5.00	4.00	5.00
58	Cerca l				4.00 AVG	4.00 AVG	5.00 AVG
59	Prenot				5.00 AVG	5.00 AVG	5.00 AVG
60	invia u				5.00 AVG	5.00 AVG	5.00 AVG
61	Scrivi u				3.00	3.00	2.00
62	Quanti				5.00 AVG	5.00 AVG	5.00 AVG
63	Mostrami i d...	[]	5.00	1.00	1.00	1.00	1.00

Risultati

Modelli economici
(gpt-5-mini/nano & Qwen3-coder)

Metrica	Media*	Dev. std	Min	Max
Request fulfilled	4.61	0.65	1	5
Groundedness	4.81	0.61	1	5
Ambiguity handling	4.96	0.28	2	5
Orchestration	4.84	0.41	1	5
Context preservation	4.56	0.85	1	5
Media complessiva	**4.75**	**0.56**	**1.2**	**5**

*Punteggi espressi su scala 1-5

Modelli performanti
(gpt-5/gpt-5-codex)

Metrica	Media*	Dev. std	Min	Max
Request fulfilled	4.74	0.58	1	5
Groundedness	4.86	0.52	2	5
Ambiguity handling	4.93	0.25	2	5
Orchestration	4.91	0.35	1	5
Context preservation	4.92	0.38	2	5
Media complessiva	**4.87**	**0.50**	**1.6**	**5**

*Punteggi espressi su scala 1-5

1M token gpt-5-nano
Input 0.05$
Output 0.40$

Configurazione	Latenza TTFT media per turno	Costo medio per turno
Modelli economici	30 s	$0.005
Modelli performanti	80 s	$0.090
Differenza	+167%	+1700%

1M token gpt-5
Input 1.25$
Output 10.00$

Conclusioni

- La PoC ha ottenuto ottimi risultati in termini di metriche con costi contenuti
- Framework stabile e governabile
- Elevato livello di tracciabilità
- Sistema facilmente scalabile ed estensibile nel tempo
- La soluzione può aggiungere latenza e overhead per processi semplici

Sviluppi futuri

- Personalizzazione su casi d’uso reali
- Raccolta di feedback espliciti in chat
- Fine-tuning mirato dei modelli LLM
- Utilizzare il protocollo MCP per i tool
- Utilizzare il protocollo A2A per la comunicazione tra agenti

Grazie per l’attenzione